

הגשת נושא הפרויקט בבינה

תפארת אהרוני 329109508

שרה ברייש 4485986X

רחל סאליקוב 329399893

אפיון פרויקט: מערכת לזיהוי העתקות בעבודות ומבחנים

תיאור כללי של הפרויקט

במסגרת מוסדות חינוך קיימת בעיה הולכת וגוברת של העתקת עבודות, מבחנים ופתרונות בין תלמידים או שימוש בתוכן קיים מהאינטרנט ללא ציון מקור. תופעה זו מקשה על הערכה הוגנת של ידע התלמידים ודורשת בדיקה ידנית מצד מורים ומרצים, שהיא לרוב איטית ולא מדויקת.

מטרת הפרויקט היא לפתח מערכת אוטומטית שתדע לנתח מסמכי טקסט ולהעריך את רמת הדמיון ביניהם, במטרה לזהות מקרים של העתקה או שימוש לא מקורי בתוכן.

המערכת תאפשר העלאה של מספר עבודות, תבצע ניתוח טקסטים, ותציג תוצאות ברורות של אחוזי דמיון בין כל זוג מסמכים, כולל סימון מקרים חשודים.

בעיית הפרויקט

הבעיה המרכזית היא חוסר יעילות בזיהוי העתקות:

- בדיקה ידנית של עבודות היא איטית ומועדת לטעויות
- קשה להשוות בין עשרות או מאות מסמכים
- העתקות לעיתים חלקיות ולא תמיד נראות לעין
- אין כלי פשוט ונגיש לבדיקת דמיון בין טקסטים

כתוצאה מכך, נוצר צורך במערכת אוטומטית שתבצע ניתוח טקסטים בצורה חכמה ומהירה.

פתרון מוצע

הפתרון הוא פיתוח מערכת בפיתוח שתבצע ניתוח טקסטים ותחשב את רמת הדמיון ביניהם.

תהליך העבודה של המערכת:

1. קבלת קבצי טקסט כקלט (עבודות של תלמידים)
 2. ניקוי ועיבוד הטקסט (הסרת סימנים, מילים מיותרות וכו')
 3. המרת הטקסט לייצוג מספרי באמצעות שיטות NLP
 4. חישוב דמיון בין המסמכים
 5. הצגת תוצאות בצורה ברורה (טבלה + אחוזי דמיון)
- בנוסף, ניתן להגדיר סף שמעליו מערכת תסמן עבודה כ"חשודה להעתקה"

כלים וטכנולוגיות מתוכננות

שפת תכנות:

- Python

ספריות עיקריות:

- scikit-learn לחישוב TF-IDF ודמיון בין טקסטים
- pandas לניהול וארגון נתונים
- numpy חישובים מספריים
- matplotlib / seaborn (הצגת גרפים) לדוגמה Heatmap של דמיון
- ניקוי טקסטים (Regex)

כלים אפשריים להרחבה:

- streamlit – יצירת ממשק משתמש פשוט להצגת תוצאות
- python-docx – קריאת קבצי Word
- PyPDF2 – קריאת קבצי PDF

שיטות עיבוד ואלגוריתמים

המערכת תשתמש בשיטות עיבוד שפה טבעית: (NLP)

- **TF-IDF (Term Frequency – Inverse Document Frequency)**
להמרת טקסט לוקטורים מספריים שמייצגים את חשיבות המילים במסמך.
- **Cosine Similarity**
לחישוב מידת הדמיון בין שני מסמכים לפי הזווית בין הווקטורים שלהם.

תוצרים צפויים

בסיום הפרויקט תתקבל מערכת שתוכל:

- להשוות בין מספר מסמכים
- לחשב אחוזי דמיון בין כל זוג עבודות
- להציג טבלה מסודרת של תוצאות
- לסמן מקרים חשודים להעתקה
- (אופציונלי) להציג ממשק גרפי נוח לשימוש