

מערכת חכמה לזיהוי העתקות בעבודות ומבחנים באמצעות NLP

פרויקט בבינה מלאכותית | תפארת אהרוני · שרה ברייש · רחל סאליקוב

ALEPHBERT

עיבוד שפה טבעית

פרויקט סיום



הגדרת הבעיה והצורך

תופעת ההעסקה במוסדות אקדמיים אינה חדשה, אך בעידן הדיגיטלי היא הפכה נפוצה ומורכבת יותר מאי פעם. סטודנטים מעתיקים בין עצמם, מתוך מאמרים מקוונים, ולעיתים מסתפקים בשינוי ניסוח שטחי כדי לסכל בדיקה ידנית. הצורך בכלי אוטומטי, מהיר ומדויק להערכת מקורות מעולם לא היה דחוף יותר.

הבעיה המרכזית

עלייה חדה בתופעת ההעסקות – הן בין עבודות סטודנטים והן שימוש בתוכן מהאינטרנט ללא ציון מקור. הבעיה קיימת בכל הרמות: מהתרגולים השבועיים ועד לפרויקטי הגמר.

קשיי הבדיקה הידנית

- תהליך איטי ומועד לטעויות אנוש – מרצה שבודק עשרות עבודות עייף ועלול להחמיץ דמיון מובהק
- קושי להשוות בין מאות מסמכים בו-זמנית – הדבר פשוט בלתי אפשרי ידנית בהיקף סביר
- העתקות חלקיות או שינויי ניסוח קלים (פרפרזה) כמעט בלתי ניתנים לזיהוי בעין אנושית
- חוסר אחידות בסטנדרטים של הערכה בין מרצים שונים

סקירת התחום — מה קיים ומה חסר?

ניתוח המצב הקיים בשוק כלי זיהוי ההעתקות חושף פערים משמעותיים, בעיקר בתחום ההבנה הסמנטית ותמיכה בשפות לא-אנגליות כגון עברית.

מה חסר ⚠️

הבנה סמנטית אמיתית: זיהוי העתקה גם כאשר הסטודנט משנה מילים אך שומר על המשמעות — למשל, "הרכב נסע" מול "המכונית נעה".

תמיכה מלאה בעברית: התמודדות עם הטייות, אותיות שימוש, ניקוד ומורפולוגיה עברית מורכבת שכלים קיימים מתקשים לטפל בה.

נגישות למרצה: ממשק פשוט, ויזואלי וברור שאינו דורש ידע טכני — המרצה צריך אינדיקציה מיידית, לא קוד.

מה קיים היום 🔍

כלים להשוואת מחרוזות (String Matching): מזהים התאמות מדויקות בין טקסטים — יעילים להעתקה מלאה אך עיוורים לכל שינוי.

מערכות מבוססות TF-IDF: מחשבות דמיון מילולי על בסיס תדירות מילים — שיפור משמעותי, אך עדיין מוגבלות לרמת המילה הבודדת ללא הקשר.

כלים מסחריים (Turnitin וכד'): פועלים בעיקר על בסיס מסדי נתונים של מסמכים קיימים ואינטרנט, ולרוב אינם מותאמים לעברית.

הפתרון המוצע – חדשנות בשילוב גישות

המערכת שפיתחנו בפייתון מציעה גישה כפולה וחדשנית: שילוב בין שיטות סטטיסטיות קלאסיות לבין מודלי שפה עמוקים, תוך התמקדות מיוחדת בשפה העברית. הפלט הוא טבלת אחוזי דמיון ברורה עם סימון אוטומטי של מקרים "חשודים" מעל סף שניתן לכוונן.



פלט ויזואלי ברור

המערכת מפיקה טבלת דמיון מסודרת עם ציון אחוזים לכל זוג מסמכים. מקרים חשודים מסומנים אוטומטית בצבע ומוצגים כ"התראות" – כך המרצה ממקד את תשומת לבו ביעילות. יתרון: נגישות גבוהה לגורמים שאינם טכניים.



גישה סמנטית – AlephBERT

מודל Transformer מבוסס BERT שאומן ספציפית על טקסטים עבריים. מסוגל לזהות דמיון משמעותי גם בין משפטים שנוסחו בצורה שונה לחלוטין – מבין "רוח הדברים" ולא רק את האות. יתרון: עמידות בפני פרפרזה ושינויי ניסוח מכוונים.




גישה סטטיסטית – TF-IDF

מתאימה לזיהוי העתקות "העתק-הדבק" ישירות. מחשבת את חשיבות כל מילה במסמך ביחס לקורפוס הכולל, ומאפשרת זיהוי מהיר ויעיל של מילים ייחודיות המשותפות לשני מסמכים. יתרון: מהירות עיבוד גבוהה מאוד גם עבור מאות מסמכים.

תהליך העבודה – Pipeline מלא מקצה לקצה

ה-Pipeline של המערכת מחולק לשלבים ברורים ומוגדרים היטב, החל מהזנת הקלט ועד להצגת הדוח הסופי. כל שלב בנוי כמודול עצמאי, מה שמאפשר גמישות ויכולת שיפור עתידי של כל חלק בנפרד.



בשלב **העיבוד המקדים** מתבצע ניקוי יסודי של הטקסט: הסרת סימני פיסוק, מילות עצירה (Stop Words), תווים מיוחדים והורדת אותיות לצורה נורמלית. בשלב ה**וקטוריזציה** הטקסט המנוקה מומר לייצוג מספרי – וקטור במרחב n-מימדי – שאותו ניתן להשוות מתמטית. חישוב ה**Cosine Similarity** מודד את הזווית בין שני וקטורים: ככל שהזווית קטנה יותר (ערך קרוב ל-1), הדמיון גבוה יותר.

אלגוריתמים ושיטות ביצוע

הבסיס המתמטי והמחקרי של המערכת שואב ממספר תחומים בלמידת מכונה ועיבוד שפה טבעית. הבנת האלגוריתמים מאפשרת להעריך את חוזקות ומגבלות כל גישה.

TF-IDF — Term Frequency— Inverse Document Frequency

שיטה סטטיסטית קלאסית המחשבת את "חשיבות" המילה במסמך ביחס לכלל הקורפוס. מילה שמופיעה הרבה במסמך אחד אך לא בשאר — תקבל ציון גבוה. כך מתאפשר זיהוי מדויק של מילים ייחודיות המשותפות לשני מסמכים, ואשר מעידות על דמיון לא מקרי. יעיל מאוד עבור "העתק-הדבק" ישיר.

Cosine Similarity — דמיון קוסינוסי

מדד מתמטי המחשב את הזווית בין שני וקטורים במרחב רב-מימדי. הנוסחה: $\cos(\theta) = (\mathbf{A} \cdot \mathbf{B}) / (|\mathbf{A}| \cdot |\mathbf{B}|)$. ערך של 1.0 מצוין זהות מלאה, ואילו 0 מצוין העדר כל קשר. היתרון הגדול של מדד זה הוא שהוא בלתי תלוי באורך המסמך — שני מסמכים בני 100 ו-500 מילים ייצאו נמדדים בצורה הוגנת.

AlephBERT — מודל שפה עברי מבוסס Transformer

מודל המבוסס על ארכיטקטורת BERT שאומן על קורפוס עצום של טקסטים עבריים. בניגוד ל-TF-IDF, AlephBERT לומד את ה"קשר" של כל מילה במשפט — ולכן מזהה ש"מכונת" ו"רכב" הן מושגים סמנטית שקולים, גם אם אין ביניהם חפיפה מילולית. המודל מייצר Sentence Embeddings — וקטורי הטמעה של משפטים שלמים — המלכדים את המשמעות הכוללת של הטקסט.

שילוב שתי הגישות — הסטטיסטית והסמנטית — מספק רשת ביטחון כפולה: TF-IDF תופס העתקות ישירות, ואילו AlephBERT מזהה פרפרזה חכמה. ביחד הם מכסים את מרבית תרחישי ההעתקה האפשריים.

מחסנית הטכנולוגיות

המערכת בנויה כולה על Python, תוך שימוש בספריות קוד פתוח מובילות בתעשייה. הבחירה בטכנולוגיות אלו מבטיחה מהימנות, תמיכה קהילתית רחבה ויכולת הרחבה עתידית.



scikit-learn

הספרייה המובילה ללמידת מכונה ב-Python. משמשת לחישוב TF-IDF ולמדדי דמיון. תומכת בוקטורизציה יעילה של כמויות גדולות של טקסט תוך אופטימיזציה של זיכרון וזמן ריצה.



Transformers (HuggingFace)

הפלטפורמה המובילה לטעינה ושימוש במודלי שפה מתקדמים. משמשת לטעינת מודל AlephBERT ולהפקת Sentence Embeddings עבורית בצורה פשוטה ויעילה.



pandas + numpy

ניהול נתונים, אחסון תוצאות הדמיון כ-DataFrame מסודר, וביצוע חישובים מספריים מהירים על מטריצות הדמיון. pandas מאפשר ייצוא נוח לאקסל ו-CSV.



Streamlit + Seaborn

JavaScript יוצר ממשק משתמש אינטראקטיבי ונוח ללא כתיבת Streamlit מציג מפות Seaborn. מרצה יכול להעלות קבצים ולראות תוצאות בלחיצה — ויזואליות לדמיון בין כל זוג מסמכים (Heatmaps) חום.

תוצרים צפויים והיתכנות הפרויקט

הפרויקט נשען על בסיס טכנולוגי מבוסס ומוכח, המפחית משמעותית את הסיכון בביצוע. כל הרכיבים המרכזיים זמינים כספריות קוד פתוח, ומודל AlephBERT זמין להורדה חינמית דרך HuggingFace Hub.

ניתוח היתכנות

טכנית: הסתמכות מלאה על מודלים קיימים וספריות בוגרות — אין צורך לאמן מודל מאפס, מה שחוסך חודשים של עבודה ומשאבי חישוב עצומים.

הרחבה עתידית: תמיכה בקבצי Word ו-PDF תתאפשר באמצעות ספריות python-docx ו-PyMuPDF. ניתן להוסיף השוואה מול מסד נתונים של עבודות קודמות.

ערך מוסף מחקרי: השוואה כמותית בין הגישה הסטטיסטית לסמנטית תאפשר להסיק מסקנות מעניינות לגבי מגבלות כל שיטה — תרומה אמיתית לשדה.

אתגרים: זמן עיבוד של AlephBERT לקורפוס גדול עשוי להיות ארוך; נדרש כוונן מיטבי של הסף לזיהוי חשד.

תוצרים מרכזיים

- מערכת השוואה המסוגלת לעבד עשרות מסמכים בו-זמנית ולהפיק מטריצת דמיון מלאה
- ממשק Streamlit נוח ופשוט לשימוש — העלאת קבצים, הגדרת סף חשד, וצפייה בתוצאות
- הצגה ויזואלית בצורת Heatmap — זוגות חשודים מודגשים בצבע
- טבלת אחוזי דמיון מפורטת הניתנת לייצוא לאקסל
- השוואה מקבילה בין ציוני TF-IDF וציוני AlephBERT לכל זוג מסמכים

דוגמה חיה – איך המערכת חושבת?

כדי להמחיש את כוח הגישה הסמנטית לעומת הסטטיסטית, הנה דוגמה קונקרטית המראה כיצד המערכת מזהה העתקה גם כשאין חפיפה מילולית ישירה.

משפט מקורי

"המהפכה התעשייתית גרמה לעלייה חדה בביקוש לעובדים בערים, ולכן אוכלוסיות רבות עזבו את הכפרים והגיעו למרכזים האורבניים."

משפט "מועתק" עם שינוי ניסוח

"עם פרוץ המהפכה התעשייתית, גדל הצורך בכוח אדם בקרב הערים, ורבים מהכפריים נדדו אל המוקדים העירוניים."

תוצאת AlephBERT

דמיון גבוה מאוד – כ-91%. המודל הסמנטי מבין שהמשמעות זהה: גידול בביקוש לעבודה בעיר, נדידה מהכפר לעיר. הוא לא נבלל מהחלפת "עלייה בביקוש" ב-"גדל הצורך" – הקשר שמור.

תוצאת TF-IDF

דמיון נמוך יחסית – כ-35%. המילים שונות מספיק כדי לבלבל את האלגוריתם הסטטיסטי. המילה "מהפכה" תואמת, אך "גרמה" מול "גדל", "עובדים" מול "כוח אדם", "ערים" מול "עירוניים" – נתפסות כשונות.

✔ זהו בדיוק הערך המוסף של הגישה הסמנטית: המערכת לא מחפשת מילים – היא מבינה משמעות. זוהי ההבחנה הקריטית בין כלי זיהוי העתקות מהדור הישן לבין הגישה שפיתחנו.

סיכום וכיוונים להמשך

הפרויקט מציג גישה מחקרית ומעשית לאתגר אמיתי ומשמעותי בעולם האקדמי. השילוב בין שיטות סטטיסטיות לסמנטיות, עם דגש על השפה העברית, ממצב אותו כתרומה ייחודית לתחום.

מה השגנו	כיוונים להרחבה	המסר המרכזי
פיתוח pipeline מלא לזיהוי העתקות בעברית, שילוב TF-IDF עם AlephBERT, ממשק ויזואלי נגיש, והדגמה כמותית של עליונות הגישה הסמנטית על הסטטיסטית בתרחישי פרפרזה.	הרחבה לתמיכה מלאה בקבצי PDF/Word, בנייה של מסד נתונים מצטבר של עבודות, כוונן אוטומטי של סף החשד בהתבסס על נתוני הקורס, ואפשרות השוואה מול מאמרים אקדמיים מרשת.	המערכת שלנו אינה רק כלי טכני – היא פתרון אקדמי שמבין שפה. הגבול בין "כתבתי בעצמי" ל"העתקתי עם שינויים" מיטשטש בעידן הדיגיטלי, וכלים כמו AlephBERT מאפשרים לשמור על יושרה אקדמית ברמה חדשה לחלוטין.

המערכת שלנו לא מחפשת מילים – היא מנסה להבין את "רוח הדברים". זהו ההבדל בין בדיקה ידנית לבין בינה מלאכותית אמיתית בשירות האקדמיה.